

Questão 1 – Análise de Outliers com Clustering

Objetivo:

Investigar a presença de grupos atípicos de passageiros que utilizam o Aeroporto Internacional de São Francisco (SFO), com base em dados demográficos, comportamentais e de satisfação. Utilizou-se o algoritmo de agrupamento KMeans para identificar clusters representativos.

Metodologia:

A análise foi estruturada em várias etapas fundamentais para garantir a robustez do modelo de clusterização:

1. Leitura e tratamento dos dados:

O dataset foi importado com codificação apropriada (latin1) e submetido à remoção de valores ausentes (NaN), garantindo a consistência dos dados de entrada.

2. Padronização dos atributos:

Foi utilizado o StandardScaler para normalizar as variáveis numéricas, passo essencial para evitar que atributos com diferentes escalas impactem negativamente o processo de agrupamento.

3. Seleção de variáveis relevantes:

Foram consideradas variáveis com potencial explicativo relevante:

- a. **NETPRO:** Nível de satisfação com o aeroporto.
- b. **Q20Age:** Faixa etária dos passageiros.
- c. **Q21Gender:** Gênero.
- d. **Q22Income:** Faixa de renda.
- e. **Q23FLY:** Frequência de voos anuais.
- f. **Q5TIMESFLOW:** Número de vezes que já voou.
- g. **Q6LONGUSE:** Tempo de uso do aeroporto.

4. Execução do algoritmo KMeans:

O número ideal de clusters ($k=4$) foi definido com base no método do cotovelo (Elbow Method), que avalia a inércia intra-cluster em função de diferentes valores de k .

5. Distribuição dos Clusters:

- a. **Cluster 0:** 49.41% dos passageiros – grupo majoritário.
- b. **Cluster 1:** 43.33% dos passageiros – grupo secundário.
- c. **Cluster 2:** 7.26% dos passageiros – grupo atípico, foco da análise.

- d. **Cluster 3 (em outro experimento):** Menor grupo (~1.9%), não considerado na versão final.

Perfil do Cluster 2 – Grupo Incomum

Este grupo representa uma fatia menor do total de passageiros, porém com características muito distintas, que justificam um olhar mais atento por parte da gestão do aeroporto.

Atributo	Valor Médio	Interpretação Detalhada
Satisfação (NETPRO)	9.53	Muito acima da média geral; demonstra satisfação elevada mesmo com uso limitado.
Idade (Q20Age)	1.17	Reflete um público muito jovem, possivelmente entre 18 e 24 anos.
Gênero (Q21Gender)	0.43	Maioria feminina neste cluster.
Renda (Q22Income)	0.14	Renda extremamente baixa; pode indicar estudantes ou população economicamente ativa de baixa renda.
Frequência de voos	0.21	Viajam pouco, sugerindo viagens esporádicas.
Experiência (Q5TIMESFLOW)	2.36	Aponta alguma experiência com voos, mas longe de serem viajantes frequentes.
Tempo no aeroporto	2.53	Utilização moderada das instalações do aeroporto.

Interpretação e Aplicações:

Este grupo, embora pequeno, representa um nicho importante:

- **Possível perfil:** Jovens universitários, turistas ocasionais, estudantes em intercâmbio, etc.
- **Necessidades específicas:** Acesso facilitado a serviços de baixo custo, boa sinalização, suporte digital (Wi-Fi gratuito, QR codes), opções acessíveis de alimentação e transporte.

- **Oportunidade de negócio:** A criação de campanhas segmentadas ou serviços personalizados (como um programa de fidelidade para novos viajantes) pode aumentar a lealdade desses usuários e melhorar sua experiência.

Questão 2 – Regras de Associação (FP-Growth)

a. Problema:

Aplicar algoritmos de regras de associação para entender padrões de compra de clientes em um varejo eletrônico. O objetivo é aprimorar estratégias de vendas, disposição de produtos e personalização de recomendações com base em padrões reais de consumo.

b. Dados Utilizados:

- **Dataset:** Sales Data.csv
- **Transações analisadas:** 6.832
- **Produtos únicos:** 19
- **Principais itens vendidos:**
 - **USB-C Charging Cable:** 21.855 unidades
 - **Lightning Charging Cable:** 21.604 unidades
 - **AAA Batteries (4-pack):** 20.593 unidades

c. Etapas da Geração de Regras:

1. Pré-processamento:

- a. Conversão para estrutura transacional: Cada linha do dataset representa uma transação com múltiplos itens.
- b. Filtragem de itens com suporte inferior a 1% para remover ruído e reduzir dimensionalidade.

2. Algoritmo utilizado:

- a. **FP-Growth:** Escolhido por sua eficiência e escalabilidade em comparação ao algoritmo Apriori.

3. Parâmetros definidos:

- a. **Suporte mínimo:** 1%

- b. **Confiança mínima:** 30%
- c. **Lift mínimo:** 1.5 (relevância da regra)

d. Top 5 Regras Geradas:

Antecedente	Consequente	Support	Confiança	Lift	Interpretação
Lightning Charging Cable	iPhone	48%	58%	2.15	Quem compra o cabo Lightning tem mais do que o dobro de chance de também comprar um iPhone. Ideal para cross-selling.
iPhone	Lightning Charging Cable	48%	54%	2.15	Relação recíproca. Sugere forte compatibilidade entre produtos Apple. Ótimo para criação de bundles.
Google Phone	USB-C Charging Cable	46%	61%	2.07	Forte indicativo de necessidade de acessórios compatíveis. Sugere recomendação automática.
Wired Headphones	USB-C Charging Cable	61%	25%	1.81	Associação moderada. Indica tendência de uso conjunto com dispositivos Android.
Apple AirPods Headphones	iPhone	55%	40%	1.34	Forte relação entre produtos do ecossistema Apple. Sugestão natural de recomendação.

Aplicações Práticas:

- **Promoções e Combos Inteligentes:**
Criar pacotes com base em combinações recorrentes.
- **Melhoria na disposição de produtos:**
No e-commerce, posicionar itens frequentemente comprados juntos como “compre também”.
- **Recomendações personalizadas:**
Sistemas automatizados podem sugerir produtos com base em padrões similares ao comportamento do cliente.

Questão 3 – Regressão Logística para Classificação de Compras de Alto Valor

a. Problema:

Desenvolver um modelo preditivo para classificar se uma compra será considerada de **alto valor** (valor total > \$500). A regressão logística foi escolhida por tratar-se de um problema de classificação binária.

b. Dados Utilizados:

- **Fonte:** Sales Data.csv
- **Variáveis utilizadas:**
 - **Quantity Ordered**
 - **Price Each**
 - **Purchase Hour**
 - **Purchase Month**
 - **Purchase City**
- **Criação do Target:**
A variável binária `high_value_purchase` foi definida como 1 quando a multiplicação de `Quantity Ordered` × `Price Each` excede \$500.

c. Etapas de Treinamento do Modelo:

1. Pré-processamento:

- One-hot encoding:** aplicado às cidades.
- SMOTE:** para balancear as classes, pois apenas 12% das compras eram de alto valor.
- StandardScaler:** usado para normalizar os dados.

2. Modelagem:

- Modelo principal: LogisticRegression(C=0.1, solver='liblinear')
- Modelo comparativo: RandomForestClassifier (benchmark)

3. Avaliação:

- Métricas: Acurácia, AUC-ROC, matriz de confusão.
- Análise de importância dos coeficientes para interpretabilidade.

d. Resultados Obtidos:

Métrica	Logistic Regression	Random Forest
Acurácia	99.95%	87.86%
AUC-ROC	99.99%	78.23%
Recall (classe minoritária)	1.00	0.00
Precision (classe minoritária)	1.00	0.00

Variável mais importante:

- Price Each (coef = 18.15)** → Altamente correlacionado com o valor total da compra.

Cidades com maior chance de compras caras:

- San Francisco, Los Angeles e Nova York.

Hora e mês:

Tiveram impacto pequeno ou negativo, indicando que fatores temporais são menos relevantes para prever o ticket médio da compra.